

PONTIFICIA UNIVERSIDAD CATÓLICA DEL PERÚ

FACULTAD DE CIENCIAS E INGENIERÍA



ESTIMACIÓN AUTOMÁTICA DE LA VARIANZA Y DISCRIMINACIÓN
DE DISTRIBUCIONES DE RUIDO EN IMÁGENES DIGITALES

Tesis para optar el Título de Ingeniero Electrónico, que presenta el bachiller:

Jaime Cesar Reátegui Woll

ASESOR: Paul Antonio Rodriguez Valderrama

Lima, 2013



Para mis seres queridos.

Resumen

Existen diversos sistemas de adquisición de imágenes, algunos de ellos son: CCD (Charge Couple Devices), sistemas basados en luz coherente, MRI (Magnetic Resonance Imaging), imágenes SAR (Radar de apertura sintética), etc. En todos los casos, las imágenes generadas se encuentran afectadas en alguna medida por distintos tipos de ruido. Se han estudiado y desarrollado diversos métodos para eliminar el ruido presente, para así obtener una mejor estimación de la escena de interés. La mayoría de algoritmos de restauración de imágenes digitales asumen que la clase de ruido y sus parámetros característicos son conocidos (p.e: varianza, coeficiente de variación, etc.).

En la presente tesis se desarrolla e implementa un algoritmo para la estimación automática de la varianza y discriminación de la distribución del ruido presente en una imagen digital. La metodología propuesta se encuentra dividida en dos bloques principales. El primer bloque estima la varianza del ruido presente en la imagen utilizando un método basado en el cálculo de la moda de las varianzas obtenidas a partir de ventanas locales (segmentos de la imagen). El segundo bloque transforma una distribución de ruido específica en una distribución Gaussiana con varianza unitaria utilizando transformaciones de estabilización de varianza. Estos dos bloques trabajan de manera conjunta y automática haciendo uso de diversas reglas de decisión para, finalmente, poder discriminar la distribución que presenta la imagen digital analizada.

El algoritmo será implementado en el software MATLAB y será capaz de discriminar entre las siguientes cuatro tipos de ruido: aditivo Gaussiano, multiplicativo Gamma, multiplicativo Rayleigh y Poisson. Los resultados computacionales se obtendrán a partir de imágenes con ruido cuya distribución y magnitud son conocidas. Los resultados obtenidos pueden ser utilizados luego para distintos tipos de pruebas.

El orden que sigue la tesis es el siguiente: En el primer capítulo se define puntualmente el problema que se busca resolver. En el segundo capítulo se cubren todos los aspectos teóricos necesarios, así como los diversos métodos, algoritmos o estudios realizados anteriormente sobre este tema. El diagrama de bloques y los detalles del algoritmo se especifican en el capítulo tres. Por último, se presentan los resultados en el capítulo cuatro seguido de las conclusiones y recomendaciones.



TEMA DE TESIS PARA OPTAR EL TÍTULO DE INGENIERO ELECTRÓNICO

Título	: Estimación automática de la varianza y discriminación de distribuciones de ruido en imágenes digitales
Área	: Procesamiento Digital de Imágenes
Asesor	: Paul Antonio Rodriguez Valderrama
Alumno	: Jaime Cesar Reátegui Woll
Código	: 20074359
Fecha	: 17/10/2011

Descripción y Objetivos

Existen diversos sistemas de adquisición de imágenes, algunos de ellos son: CCD (Charge Couple Devices), láser, MRI (Magnetic Resonance Imaging), imágenes SAR (Radar de apertura sintética), etc. En todos los casos, las imágenes generadas se encuentran afectadas en alguna medida por distintos tipos de ruido. Típicamente, la mayoría de algoritmos de restauración de imágenes digitales asumen que la clase de ruido, y sus parámetros característicos son conocidos (p.e.: varianza, coeficiente de variación, etc.).

En la presente tesis se implementa y desarrolla un algoritmo para la estimación automática de la varianza y discriminación de distribuciones de ruido presente en una imagen digital. La metodología propuesta se encuentra dividida en dos bloques principales. El primer bloque estima la varianza del ruido presente en la imagen utilizando un método basado en el cálculo de la moda de las varianzas obtenidas a partir de ventanas locales (segmentos de la imagen). El segundo bloque transforma una distribución de ruido específica en una distribución Gaussiana con varianza unitaria utilizando transformaciones de estabilización de varianza. Estos dos bloques trabajan de manera conjunta y automática haciendo uso de diversas reglas de decisión para, finalmente, poder discriminar la distribución que presenta la imagen digital analizada.

El algoritmo será implementado en el software MATLAB. Estimará la varianza y discriminará entre las siguientes distribuciones de ruido: Gaussiano, Poisson, Gamma y Rayleigh.

TEMA DE TESIS PARA OPTAR EL TÍTULO DE INGENIERO ELECTRÓNICO

Título : Estimación automática de la varianza y discriminación de la distribución de ruido en imágenes digitales

Índice

Introducción

1. Problemática
2. Varianza: estimación y transformaciones de estabilización
3. Diseño del algoritmo propuesto
4. Implementación y resultados computacionales

Conclusiones

Recomendaciones

Bibliografía

Anexos

Índice general

Introducción	1
1. Problemática	3
1.1. Descripción y formulación del problema	3
1.2. Objetivos	4
1.3. Importancia y justificación del estudio	4
1.4. Limitaciones	6
2. Varianza: estimación y transformaciones de estabilización	7
2.1. Antecedentes	7
2.1.1. Operadores de estimación de varianza	7
2.1.1.1. Estimadores globales	8
2.1.1.2. Estimadores locales	8
2.1.2. Transformaciones de estabilización de varianza	9
2.2. Aspectos conceptuales pertinentes	10
2.2.1. Imágenes digitales	10
2.2.2. El ruido	10
2.2.3. Ruido Gaussiano	11
2.2.3.1. Función de densidad Gaussiana	11
2.2.4. Ruido Gamma	11
2.2.4.1. Función de densidad Gamma	12
2.2.4.2. VST Gamma	13
2.2.5. Ruido Rayleigh	14
2.2.5.1. Función de densidad Rayleigh	14
2.2.5.2. VST Rayleigh	14
2.2.6. Ruido Poisson	15
2.2.6.1. Función de densidad Poisson	15

2.2.6.2. VST Poisson	17
--------------------------------	----

3. Diseño del algoritmo propuesto	18
3.1. Consideraciones de diseño	18
3.1.1. Características de las imágenes para el diseño	18
3.1.2. Condiciones de frontera o bordes	18
3.2. Diagrama de bloques	19
3.3. Descripción del algoritmo	20
3.3.1. Estimador de parámetros	20
3.3.2. VST utilizadas	24
3.3.2.1. Test estadístico de Lilliefors	25
3.3.3. Reglas de decisión	25
3.3.4. Discriminador de ruido	28
3.3.5. Obtención de variables características	30
4. Implementación y resultados computacionales	31
4.1. Consideraciones de implementación	31
4.1.1. Software de implementación	31
4.1.2. Tamaño del bloque en el estimador de varianza	31
4.1.3. Características de las imágenes para la implementación	31
4.2. Descripción de la implementación	32
4.2.1. Función estimación de parámetros	32
4.2.2. Función discriminación de ruido	33
4.3. Resultados computacionales	33
4.3.1. Resultados del discriminador de ruido	33
4.3.2. Análisis de los resultados	33
Conclusiones	36
Recomendaciones	37
Bibliografía	38

Introducción

Desde los inicios en la materia de procesamiento digital de imágenes, el ruido ha sido un problema. El punto de partida de una gran gama de aplicaciones electrónicas en general es la recepción de imágenes (p.e.: navegación de robots, navegación automática, reconocimiento y mapeo aéreo, sistemas de vigilancia, etc.[1]). Estas son procesadas de la forma más adecuada para poder obtener resultados útiles en la aplicación correspondiente. Toda imagen capturada por alguna cámara digital o algún otro dispositivo de adquisición de imágenes presenta diferentes tipos de ruido que dependen de las características del ambiente, del equipo, del operador (si es que lo hay), de la transmisión de datos, etc. Debido a esto, las imágenes no siempre pueden ser procesadas de manera directa ya que se obtendría en muchos casos un alto porcentaje de error que podría llevar a la obtención de resultados no deseados ni confiables (baja efectividad).

El procesamiento digital de imágenes se ha desarrollado de manera sostenida y rápida. De la misma manera se han desarrollado diversos métodos de tratamiento de ruido en imágenes que requieren conocer la varianza del mismo para poder procesar la imagen de manera adecuada (p.e: segmentación, restauración, eliminación de ruido, inferencia estadística, etc.). Para aplicar estos métodos, incluyendo la eliminación de ruido (ya sea aditivo, multiplicativo o algún otro tipo) se debe conocer la distribución de probabilidad del mismo, es decir, se debe saber qué tipo de ruido está presente en la imagen, para luego obtener sus parámetros (p.e: λ en el caso de una distribución Poisson, σ en el caso de una distribución Rayleigh, etc.). Existen modelos de ruido muy conocidos (p.e.: aditivo, multiplicativo, de disparo, etc.) con distintas distribuciones de probabilidad (p.e: Gaussiano, Poisson, Gamma, Rayleigh, Rician, etc.). Todos ellos son estudiados de manera incansable para formular distintos estimadores cada vez más efectivos que permitan obtener sus parámetros y así poder tratarlos de la mejor manera sin afectar la información útil.

Por otro lado, debido a la gran variedad de ruidos presentes en imágenes y el hecho de que muchos de estos presentan una dependencia entre la varianza y la media (lo cual complica diversos estudios), existen transformaciones de estabilización de varianza. Una transformación

de estabilización de varianza es una función (transformación) diseñada para lograr una independencia entre la media y la varianza en un conjunto de datos que sigue una distribución de probabilidad específica, todo esto como paso preliminar en diversas aplicaciones (p.e: análisis de varianza).

En resumen, existen casos en los cuales es necesario conocer la distribución y los parámetros del ruido presente en la imagen para poder aplicar el método de tratamiento adecuado (el que en teoría lograría obtener mejores resultados). Es por esto que se buscará automatizar la discriminación de la distribución del ruido, utilizando transformaciones de estabilización de varianza [2] y un operador de estimación de parámetros que utiliza bloques (segmentos de imagen) y la moda como medida [3].



Capítulo 1

Problemática

1.1. Descripción y formulación del problema

El punto de partida de cualquier aplicación que involucre procesamiento digital de imágenes, es la imagen en sí. Al adquirir una imagen digital se obtiene también ruido que depende del sistema de adquisición utilizado. Diversos sistemas de adquisición generan comúnmente diversos tipos de ruido. En líneas generales, el ruido es una perturbación que se presenta en imágenes (así como en otros conjuntos de datos) y las altera de distintas formas (distintos tipos de ruido con diversas características). Debido a esto, imágenes alteradas no siempre pueden ser objeto de estudio o análisis sin antes recibir algún tipo de tratamiento.

Es por esto que un aspecto muy importante en el procesamiento de una imagen digital es el tratamiento del ruido (p.e.: eliminación, reducción, etc.). Existen gran cantidad de estudios enfocados a la eliminación del ruido debido a la gran diversidad de distribuciones de probabilidad con las que se presenta en todo tipo de señal (incluyendo imágenes). Para lograr aplicar algún método de eliminación de ruido de forma satisfactoria se requiere tener una mínima noción del ruido presente, es decir, conocer su distribución de probabilidad y los parámetros que la definen.

En general, en situaciones reales, al adquirir una imagen no es posible determinar con claridad la distribución de ruido presente, especialmente cuando no se conoce la procedencia de la misma (no se tiene información del sistema de adquisición utilizado) por lo que es difícil seleccionar el mejor método de eliminación de ruido o al menos el más eficiente. Debido a esto, en ciertos casos se elige una distribución aproximada o simplemente una distribución típica para la situación particular, por ejemplo, en casos como [4] o [5] en donde se trabaja en imágenes obtenidas por ultrasonido, se asumen modelos multiplicativos debido a estudios anteriores y a adaptaciones a los datos sin conocer realmente si existe alguna otra distribución

de probabilidad que se ajusta mejor al ruido presente.

Por otro lado, existen estudios enfocadas a la eliminación o reducción de ruido de manera automática. Aquí el problema principal se concentra en la elección del filtro a utilizar en cada caso o en cada imagen recibida. En casos como [6] o [7] se utilizan métodos complicados que trabajan con técnicas de umbralización múltiple sobre regiones homogéneas en la imagen digital para la identificación automática del ruido presente.

1.2. Objetivos

- Estimar la varianza y el coeficiente de variación del ruido presente en una imagen digital utilizando la moda de los resultados locales presentes en la misma.
- Estimar la distribución del ruido presente en una imagen a partir de la varianza estimada y diversas transformaciones de estabilización de varianza (específicamente transformaciones para distribuciones Gamma, Rayleigh y Poisson).
- Implementar una aplicación en el software MATLAB capaz de discriminar la distribución de ruido presente en una imagen digital.

1.3. Importancia y justificación del estudio

Esta tesis busca resolver un problema presente en diversas áreas de influencia del procesamiento de imágenes digitales de manera práctica y sencilla. El problema radica en identificar de forma precisa qué tipo de distribución presenta el ruido en una imagen para elegir el método más adecuado para tratar dicho tipo de ruido. Al discriminar el ruido se puede colaborar con un gran número de aplicaciones que utilizan algún tipo de procesamiento de imágenes, ayudando a mejorar la calidad de los datos a procesar.

Existen muchos estudios e investigaciones que se especializan en algún modelo de ruido en específico para mejorar los resultados de algún proceso (p.e: filtros de eliminación de ruido, caracterización de materiales, etc.). Debido a esto, poder conocer de antemano la distribución de ruido o el modelo de probabilidad de los datos a trabajar puede ayudar a seleccionar un algoritmo que se adapte perfectamente a la situación en cuestión.

Por ejemplo, el filtro o algoritmo de eliminación de ruido presentado en [8] está diseñado específicamente para ruido multiplicativo y se basa en distintos modelos de variación para las distribuciones de probabilidad Gaussiana, Gamma, Poisson y Rayleigh. A pesar de ser un solo algoritmo, depende de los parámetros del ruido presente para lograr los resultados de

eliminación deseados. De igual manera, el filtro presentado en [9] está diseñado a partir del modelo matemático del ruido Poisson (ruido de disparo).

En los casos en que se tiene una imagen con ruido, asumir alguna distribución en particular llevaría (en ciertos casos) a la elección de un filtro o algoritmo inadecuado. Para demostrar esta idea se llevó a cabo un pequeño experimento en donde se tomó una imagen (escalada en intensidad entre 0 y 1) y se le aplicó ruido aditivo con distribución Gaussiana con varianza 0.01 y 0.1. Luego se aplicaron dos algoritmos de eliminación de ruido: el algoritmo RAMF (Rank over based adaptive median filter [10]), el cual está diseñado para la eliminación de ruido sal y pimienta, y el algoritmo IRNTV (Iteratively reweighted norm method [11]), el cual se utiliza para eliminación de ruido aditivo Gaussiano.

Para la comparación se utilizaron dos métricas: La relación señal a ruido (SNR) y el índice de similaridad estructural (SSIM). Los resultados se muestran en la Tabla 1.1 así como en la Figura 1.1. Como se esperaba, el algoritmo diseñado para eliminar ruido aditivo Gaussiano presenta mucho mejores resultados.

Tabla 1.1: Comparación entre IRNTV y RAMF.

Métrica	Varianza	Imagen con ruido	IRNTV	RAMF
SNR(dB)	0.01	5	11.9	7.3
	0.1	-3	8.8	0
SSIM	0.01	0.156	0.702	0.248
	0.1	0.032	0.54	0.062

Otro punto importante del desarrollo de esta tesis es el impacto que podría tener sobre diversas áreas de investigación enfocadas al desarrollo de algoritmos basados en modelos específicos de ruido. La idea de poder conocer de antemano la distribución de ruido presente en los datos a trabajar suena alentadora para cualquier investigador dedicado al desarrollo de algoritmos como los descritos anteriormente, por lo que de alguna manera se lograría fomentar el desarrollo e investigación de los mismos.

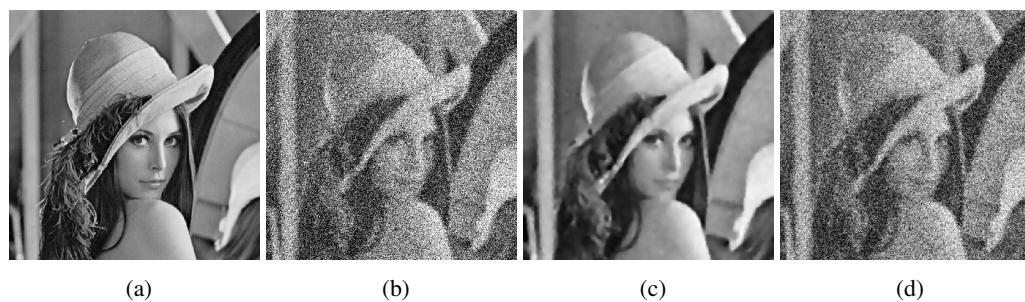


Figura 1.1: Prueba con ruido de varianza 0.1 en donde: (a) imagen original, (b) imagen con ruido, (c) aplicando IRNTV y (d) aplicando RAMF.

1.4. Limitaciones

- Existen muchos casos en los que la imagen adquirida contiene una mixtura de ruidos, los cuales presentan distribuciones conjuntas como la presentada en [12]. Estas distribuciones se encuentran fuera del alcance de esta tesis.
- Existen pocas investigaciones sobre transformaciones de estabilización de varianza utilizadas para la estimación de distribución de ruido en imágenes. Esto restringe la información útil de la que se puede partir en esta tesis.



Capítulo 2

Varianza: estimación y transformaciones de estabilización

2.1. Antecedentes

En un inicio, debido al costo del hardware necesario para procesar las imágenes, sólo se trabajó en organizaciones como el Massachusetts Institute of Technology [13]. Poco a poco el costo del hardware fue disminuyendo, por lo que el área de influencia del procesamiento de imágenes fue creciendo, invadiendo hoy en día áreas como la agricultura, seguridad, construcción, calidad, etc. Actualmente se puede utilizar en casi cualquier aplicación electrónica.

Existe teoría que involucra la discriminación de ruido en imágenes digitales (p.e: [6], [7] y [14]), pero no se encontró una investigación importante que utilice transformaciones de estabilización de varianza para lograr el objetivo. Por otro lado, la discriminación de ruido en esta tesis se basa en diversas herramientas (p.e.: estimador de varianza, estimación de coeficiente de variación, transformaciones de estabilización de varianza para distintas distribuciones de ruido, etc.), las cuales han sido investigadas y desarrolladas de manera independiente.

2.1.1. Operadores de estimación de varianza

Como se mencionó anteriormente, hoy en día existen muchos métodos, algoritmos y operadores (algunos de los cuales se describirán más adelante) para estimar la varianza del ruido presente en imágenes. Por otro lado, existen distintas características por las que se clasifican estos métodos, lo cual hace difícil el seguimiento y entendimiento de todos ellos. A continuación se intenta mostrar una clasificación adecuada para poder brindar una idea clara

de la base existente en lo que respecta a la obtención de la varianza.

Una primera división importante que se puede hacer al hablar de estimadores de varianza es el de estimación utilizando múltiples imágenes o utilizando una sola imagen [15]. En este caso, no se toma en cuenta los estimadores que utilizan múltiples imágenes para la obtención de los parámetros del ruido ya que este escenario se encuentra más allá de lo planteado en la tesis.

Los estimadores basados en una sola imagen pueden a su vez clasificarse en función de la extensión espacial empleada al estimar los parámetros del ruido como: estimadores globales y estimadores locales.

2.1.1.1. Estimadores globales

Los estimadores globales son aquellos basados en algoritmos que se aplican a la imagen completa asumiendo un gran bloque de píxeles. Estos estimadores aplican distintos algoritmos a toda la imagen. En algunos casos, eliminan de alguna forma la imagen en sí, para obtener solo el ruido y así poder calcular la varianza del mismo. En otros casos, se altera la imagen con algún algoritmo matemático para luego obtener la varianza del ruido. El problema que presentan estos estimadores es que requieren de una gran capacidad computacional en comparación con los estimadores locales debido a la gran cantidad de píxeles que se trabajan (p.e: algoritmos como la transformada rápida de Fourier requieren de $N \log N$ operaciones, donde N representa el número de datos a procesar). Ejemplos de estos estimadores se pueden encontrar en [16], [17] y [18].

2.1.1.2. Estimadores locales

Los estimadores locales dividen la imagen en pequeños bloques para aplicar algún algoritmo de manera local y obtener resultados a partir de todos ellos (p.e.: media, moda, mediana, etc.). El principio de funcionamiento se basa en lo siguiente: al dividir una imagen en pequeños bloques, los píxeles presentes en cada uno de estos presentan una distribución casi uniforme (sin textura). Gracias a esta uniformidad en la intensidad de los píxeles es posible aplicar diversas operaciones por bloque. Una vez obtenidos los resultados locales, se juntan de alguna manera para obtener el ruido de manera global. Ejemplos de estimadores de este tipo son [19], [20] y el utilizado en esta tesis.

2.1.2. Transformaciones de estabilización de varianza

Una transformada de estabilización de varianza está definida como una función que transforma la distribución de un conjunto de datos a una distribución en donde la varianza es independiente de la media [21]. Las transformaciones de estabilización de varianza son estudiadas debido a que muchos algoritmos estadísticos tradicionales se basan en la independencia de la varianza respecto de la media (p.e.: regresión lineal [22]), esta condición es llamada homocedasticidad.

Existen tantas transformaciones de varianza como distribuciones de probabilidad. Para obtener una transformación de estabilización de varianza existe un método general. El método que se muestra a continuación ha sido extraído de [23]:

Consideremos una variable aleatoria X con $E(X) = \mu$ y sea $h : I \rightarrow \mathbb{R}$ una función diferenciable, donde I es un intervalo que contiene al rango de X . Haciendo la expansión de Taylor de h de primer orden alrededor de μ tenemos:

$$h(X) \approx h(\mu) + h'(\mu)(X - \mu) \quad (2.1)$$

Resulta entonces que la varianza de $h(X)$ es aproximadamente:

$$\text{Var}(h(X)) \approx h'(\mu)^2 \text{Var}(X) \quad (2.2)$$

Ahora, supongamos que X es una familia de variables aleatorias reales que satisfacen $E(X) = \mu$ y cuyas varianzas dependen de la media, es decir, $\text{Var}(X) = g(\mu)$. Si queremos encontrar una función h tal que $\text{Var}(h(X))$ sea aproximadamente independiente de μ podemos establecer que h verifique:

$$h'(\mu)^2 g(\mu) = cte \quad (2.3)$$

Una función h que tenga esta propiedad se llama función estabilizadora de varianza. Por lo tanto, podemos obtener una transformación h que estabilice la varianza integrando $h'(\mu) = g(\mu)^{-\frac{1}{2}}$:

$$h(\mu) = \int^X \frac{1}{\sqrt{g(\mu)}} d\mu \quad (2.4)$$

Si h es una transformación obtenida de esta forma, entonces $\text{Var}(h(X)) \approx 1$. Existen diversas VST ya determinadas para distintas distribuciones de probabilidad como: Poisson, binomial o binomial negativa [24].

2.2. Aspectos conceptuales pertinentes

2.2.1. Imágenes digitales

Una imagen digital se puede definir como cualquier tipo de imagen que ha sido convertida a un formato binario conformado por ceros y unos [1] (existen ciertos casos en donde la imagen es generada directamente en formato binario). Existen muchos tipos de imágenes caracterizadas por cómo se obtienen las mismas, así como de qué tipo de formatos digitales existen para representarlas (p.e.: binario, escala de grises, rgb, etc.).

2.2.2. El ruido

A continuación, explicaremos nociones básicas de ruido tomando como base [1] (incluyendo las imágenes mostradas). El ruido es considerado como cualquier perturbación sobre una señal, ya sea analógica o digital, en este caso nos concentraremos en imágenes digitales. El ruido se puede dividir generalmente en dos grandes grupos: ruido aditivo y ruido multiplicativo. Esta división no incluye a todos los tipos de ruido presentes en la naturaleza (p.e.: ruido Poisson también llamado ruido de disparo).

Supongamos que tenemos una imagen representada por la letra f , la cual se descompone en la información útil de la imagen g y una componente de ruido q , entonces tenemos:

Modelo de ruido aditivo:

$$f = g + q \quad (2.5)$$

Modelo de ruido multiplicativo:

$$f = g * q \quad (2.6)$$

Estos dos modelos se utilizan para representar distintos tipos de ruido. Por ejemplo, podemos tener ruido aditivo con distribución de probabilidad Rayleigh o ruido multiplicativo con distribución de probabilidad Gaussiana. Para poder estudiar la naturaleza del ruido, debido a su aleatoriedad, es necesario utilizar fundamentos probabilísticos para determinar ciertas características importantes del mismo.

Existen muchos tipos de ruido, los cuales presentan distintas distribuciones de probabilidad, que a su vez son originados en distintas situaciones y debido a distintos factores. A continuación se presentan los cuatro tipos de distribución de ruido que se trabajarán en la tesis: aditivo con distribución de probabilidad Gaussiana, Poisson (ruido de disparo), multiplicativo con distribución de probabilidad Gamma y multiplicativo con distribución de

probabilidad Rayleigh (durante el desarrollo de la tesis se hablará de ruido Gaussiano, ruido Poisson, ruido Gamma y ruido Rayleigh respectivamente).

2.2.3. Ruido Gaussiano

El ruido aditivo Gaussiano es muy común en imágenes digitales ya que se utiliza como modelo de diversas perturbaciones entre las cuales se encuentran: el ruido térmico (debido a las vibraciones de los átomos en los filamentos de cobre en la transmisión de datos), el ruido debido a fuentes celestiales (p.e.: el Sol), el ruido debido a la radiación de cuerpos negros, etc.

2.2.3.1. Función de densidad Gaussiana

La función de densidad de la distribución Gaussiana se presenta a continuación:

$$P(q) = (2\pi\sigma^2)^{-\frac{1}{2}} e^{-\frac{(q-\mu)^2}{2\sigma^2}} \quad (2.7)$$

En donde q representa una variable aleatoria, la varianza es igual a σ^2 , la media es igual a μ y el coeficiente de variación es igual a $\frac{\sigma}{\mu}$. La gráfica de la función de densidad se presenta en la Figura 2.1, así como una imagen corrompida con ruido Gaussiano en la Figura 2.2.

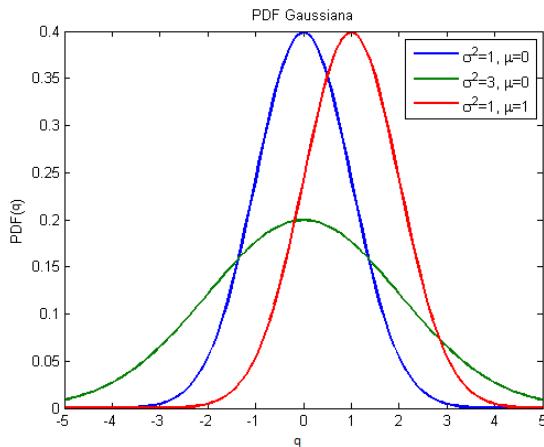


Figura 2.1: Distintos casos de la función de probabilidad Gaussiana.

2.2.4. Ruido Gamma

El ruido multiplicativo Gamma es muy conocido en la literatura. Este ruido aparece en imágenes obtenidas a partir de luz coherente (láser), SAR (radares de apertura sintética), ultrasonido y sonar. En todos estos casos existe una perturbación denominada ruido Speckle, el cual es ruido multiplicativo que se puede modelar como ruido Gamma [25].

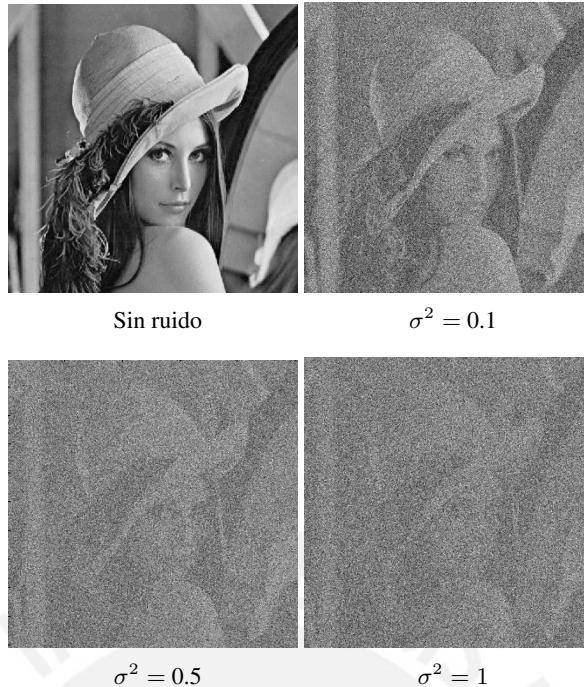


Figura 2.2: Imagen de Lena contaminada con distintas intensidades de ruido Gaussiano.

2.2.4.1. Función de densidad Gamma

Ahora se describirá la distribución Gamma en base a [26]. La función de densidad Gamma se presenta a continuación:

$$P(q) = \frac{\lambda^\alpha}{\Gamma(\alpha)} q^{\alpha-1} e^{-q\lambda} \quad (2.8)$$

Donde $\lambda \geq 0$ (parámetro de forma), $\alpha \geq 0$ (parámetro de escala) y $\Gamma(\alpha)$ es la función Gamma la cual está definida por:

$$\Gamma(\alpha) = \int_0^\infty t^{\alpha-1} e^{-t} dt \quad (2.9)$$

La función de densidad descrita solo existe para valores de $q \geq 0$. En este caso, la media es igual a α/λ , la varianza a α/λ^2 y el coeficiente de variación a $\alpha^{-\frac{1}{2}}$. La gráfica de la función de densidad se presenta en la Figura 2.3, así como una imagen corrompida con ruido Gamma en la Figura 2.4. Esta distribución se puede reducir, restringiendo sus parámetros, a diversas distribuciones como por ejemplo:

- Exponencial ($\alpha = 1$)
- Chi-cuadrado ($\alpha = N/2$, $\lambda = 1/2$, donde N indica el número de grados de libertad)
- Erlang ($\alpha = N$, donde N es el número de distribuciones exponenciales sumadas)

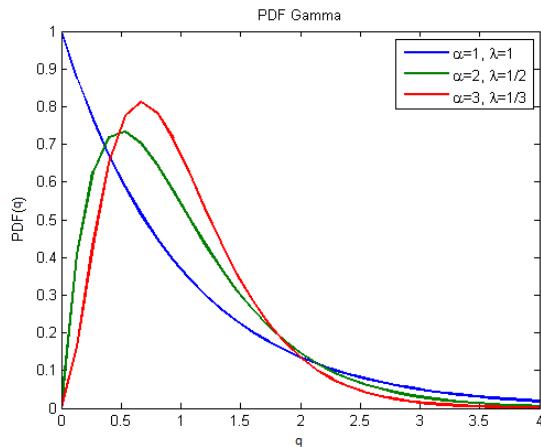


Figura 2.3: Distintos casos de la función de probabilidad Gamma.



Figura 2.4: Imagen de Lena contaminada con distintas intensidades de ruido Gamma.

2.2.4.2. VST Gamma

La transformación de estabilización de varianza para la distribución Gamma [27] se muestra en la ecuación 2.10. En este caso, la VST no solo depende de los datos, sino también del parámetro α de la función de densidad Gamma. En el caso de ruido multiplicativo Gamma, la transformación de estabilización de varianza produce como resultado ruido aditivo con distribución Gaussiana.

$$y(x) = \sqrt{\alpha} \ln \left(\frac{x}{\alpha - \frac{1}{2}} \right) \quad (2.10)$$

2.2.5. Ruido Rayleigh

El ruido multiplicativo Rayleigh, así como el Gamma, es muy estudiado. Este ruido se presenta generalmente en imágenes de resonancia magnética (MRI). En realidad, se presenta ruido con distribución Rician, la cual es una distribución general que modela en ciertos casos a la distribución Rayleigh [28].

2.2.5.1. Función de densidad Rayleigh

Ahora se describirá la distribución del ruido Rayleigh utilizando como base la misma fuente que en el caso de la distribución Gamma. La función de densidad de la distribución Rayleigh se presenta a continuación:

$$P(q) = \frac{q}{\sigma^2} e^{-\frac{1}{2} \frac{q^2}{\sigma^2}} \quad (2.11)$$

La función de densidad descrita solo existe para valores de $q \geq 0$. En este caso, la media es igual a $\sqrt{\frac{\pi\sigma^2}{2}}$, la varianza a $(2 - \frac{\pi}{2})\sigma^2$ y el coeficiente de variación a $\sqrt{\frac{4}{\pi} - 1}$ (constante). La gráfica de la función de densidad se presenta en la Figura 2.5, así como una imagen corrompida con ruido Rayleigh en la Figura 2.6.

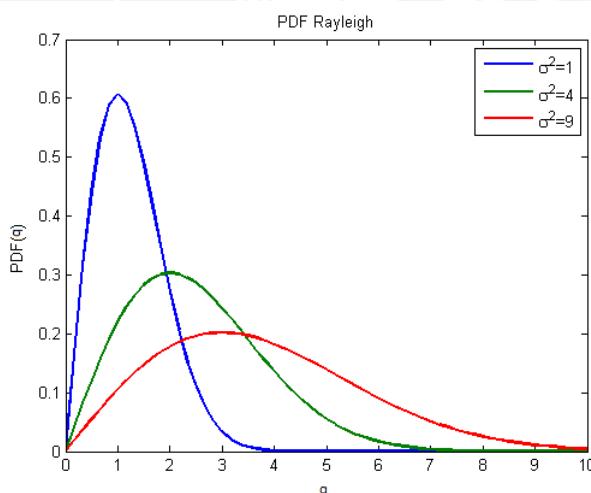


Figura 2.5: Distintos casos de la función de probabilidad Rayleigh.

2.2.5.2. VST Rayleigh

La transformación de estabilización de varianza para la distribución Rayleigh [29] se muestra en la ecuación 2.12. En el caso de ruido multiplicativo Rayleigh, la transformación de estabilización de varianza produce como resultado ruido aditivo con distribución Gaussiana.

$$y(x) = 2\sqrt{6}\pi^{-1} \ln(x) \quad (2.12)$$



Figura 2.6: Imagen de Lena contaminada con distintas intensidades de ruido Rayleigh.

2.2.6. Ruido Poisson

A diferencia de los tipos de ruido mencionados anteriormente, el ruido Poisson no es ruido aditivo ni multiplicativo. Un ejemplo claro de ruido Poisson es el generado debido a la cuenta de fotones, este se da en la mayoría de sistema de adquisición de imágenes que se basan en ese principio (p.e.: charged couple devices (CCD)).

2.2.6.1. Función de densidad Poisson

Ahora se describirá el ruido Poisson en base a [30]. Supongamos que $q_i = 1, \dots, N$, representa los valores obtenidos del pixel en observación utilizando un dispositivo de adquisición de imágenes. Consideraremos entonces que cada q_i es una variable independiente con distribución Poisson cuya media $\lambda \geq 0$ es el valor de intensidad a estimar.

La función de densidad discreta de Poisson para cada valor de q_i es:

$$P(q_i) = \frac{e^{-\lambda} \lambda^{q_i}}{q_i!} \quad (2.13)$$

Una de las principales características de esta distribución es que la media y la varianza son iguales a λ , por lo que el coeficiente de variación es constante e igual a 1. Por otro lado, la desviación estándar del ruido es igual a $\sqrt{\lambda}$, debido a esto, el efecto del ruido Poisson aumenta en la medida en que la intensidad disminuye.

Cuando el valor de λ es muy grande, la distribución Poisson se puede aproximar a una distribución Normal o Gaussiana en base al teorema del límite central [31]. Por ejemplo, una variable aleatoria con distribución Poisson con $\lambda = 100$ puede interpretarse como la suma de 100 variable aleatorias con distribución Poisson con $\lambda = 1$. La función de densidad se presenta en la Figura 2.7, así como una imagen corrompida con ruido Poisson en la Figura 2.8.

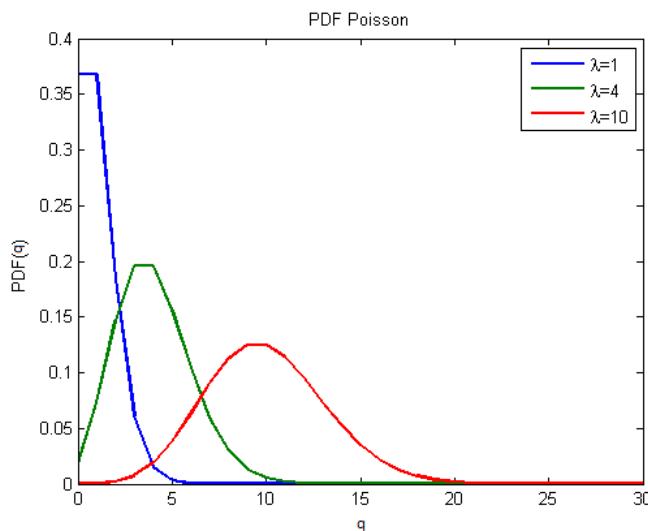


Figura 2.7: Distintos casos de la función de probabilidad Poisson.



Figura 2.8: Imagen de Lena contaminada con distintas intensidades de ruido Poisson.

2.2.6.2. VST Poisson

Existen diversas transformaciones de estabilización de varianza para la distribución Poisson. En este caso, se presentarán tres de ellas: Anscombe [24], Bartlett [32] y Freeman-Tukey [33].

Transformación Anscombe:

$$y(x) = 2\sqrt{x + \frac{3}{8}} \quad (2.14)$$

Transformación Bartlett:

$$y(x) = \sqrt{x} \quad (2.15)$$

Transformación Freeman-Tukey:

$$y(x) = \sqrt{x + 1} + \sqrt{x} \quad (2.16)$$

En el caso de ruido Poisson, la transformación de estabilización de varianza produce como resultado ruido aditivo con distribución Gaussiana [30].

Capítulo 3

Diseño del algoritmo propuesto

3.1. Consideraciones de diseño

3.1.1. Características de las imágenes para el diseño

Las imágenes utilizadas en el diseño del algoritmo se emplean por convención en aplicaciones de procesamiento digital de imágenes, el banco de seis imágenes se muestra en la Figura 3.1. En este caso, se contaminaron con uno de los cuatro tipos de ruido descritos a lo largo del documento (Gaussiano, Gamma, Rayleigh y Poisson). El tamaño de estas imágenes es de 512x512 pixeles, sin embargo, no existe una limitación en el tamaño de la imagen a ser procesada utilizando el algoritmo planteado. Todas las imágenes fueron escaladas entre 0 y 1.

Como se explicó anteriormente, las imágenes a las cuales está enfocado el algoritmo presentan poca textura (varianzas locales aproximadamente cero). En la Figura 3.2 se muestra una comparación entre un bloque de 3x3 pixeles de Lena (imagen con poca textura) y otro de Straw (imagen con textura considerable), en donde se puede apreciar claramente la diferencia entre las intensidades de los pixeles dentro de un mismo bloque.

3.1.2. Condiciones de frontera o bordes

Debido a que el algoritmo estimador de varianza se basa en pequeñas ventanas de $N \times N$ pixeles que se trasladan por toda la imagen pixel por pixel, en el caso de las fronteras, la ventana reduce su tamaño y se adapta para tomar los pixeles correspondientes, es decir, no se utiliza ningún tipo de marco o relleno (padding) en la imagen.

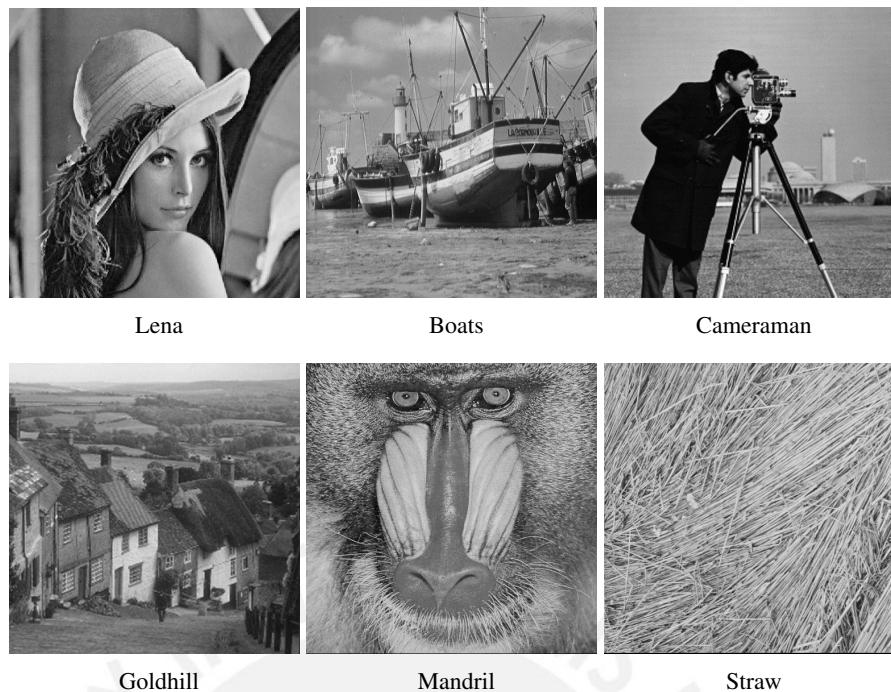


Figura 3.1: Banco de imágenes utilizado para la implementación y resultados del algoritmo.

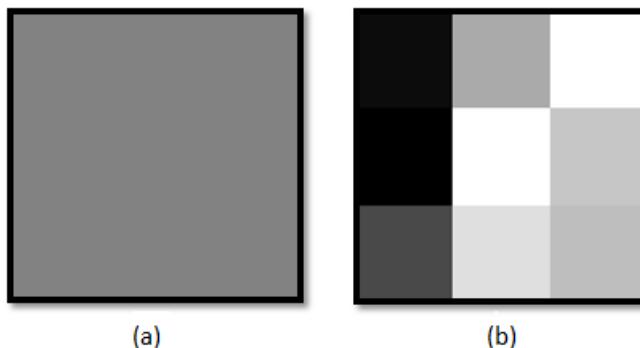


Figura 3.2: Bloques de 3x3 pixeles de la imagen de (a) Lena y (b) Straw.

3.2. Diagrama de bloques

El diagrama de bloques del algoritmo planteado se presenta en la Figura 3.3. Como parámetro de entrada se recibe una imagen cualquiera contaminada con un ruido desconocido. La imagen de entrada pasa por diversos bloques. Primero se obtienen los parámetros del ruido presente en la imagen (estimación de varianza y coeficiente de variación del ruido). Luego se aplican las diversas transformaciones de estabilización de varianza. Por último, se analizan los resultados y se aplican reglas para tomar una decisión y así poder discriminar el ruido presente en la imagen.

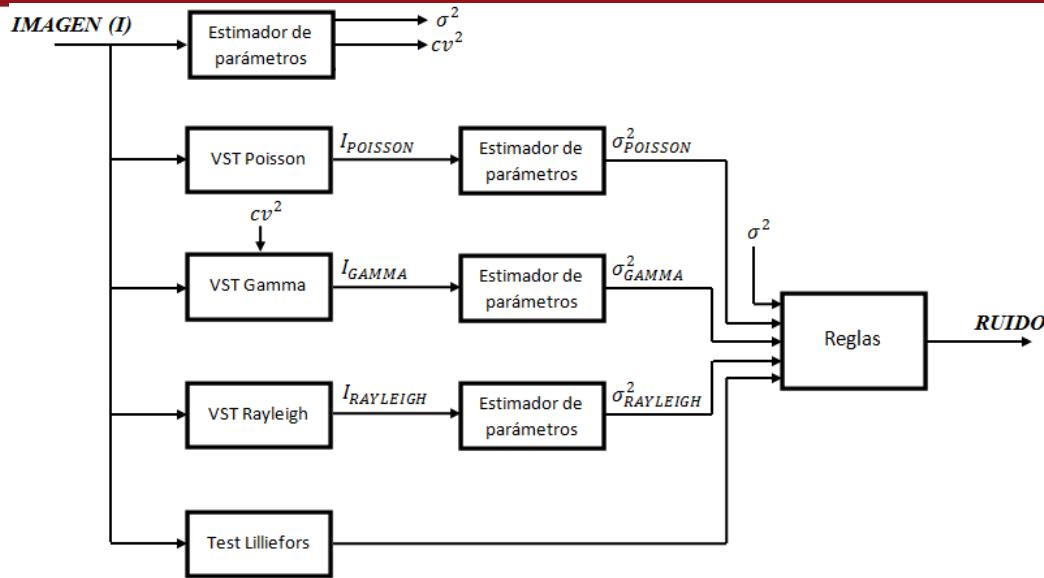


Figura 3.3: Diagrama de bloques del algoritmo propuesto (σ y cv representan la desviación estándar y el coeficiente de variación respectivamente).

3.3. Descripción del algoritmo

El algoritmo discriminador de ruido consta de tres bloques importantes, el estimador de parámetros, las transformaciones de estabilización de varianza (para las distribuciones Gamma, Rayleigh y Poisson) y ciertas reglas de decisión.

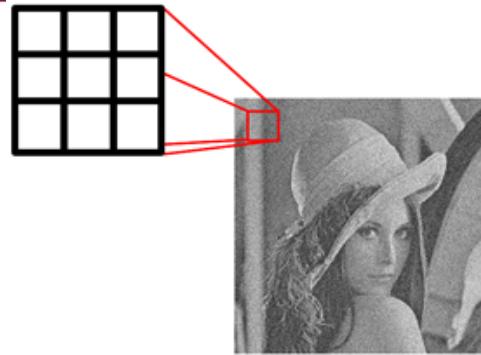
3.3.1. Estimador de parámetros

El estimador de parámetros se basa en [3]. Consideremos los píxeles de una imagen g_k , $k = 1, 2, \dots, N$ contaminada con ruido aditivo n_k produciendo la imagen f_k . Se toman pequeños bloques $B_{k,w}$ (Figura 3.4) de la imagen f_k , en donde w es el radio máximo de los píxeles presentes en el bloque que rodean al pixel central (donde $P = (2 * w + 1)^2$ es el número de píxeles en el bloque). Luego la varianza en ese pixel se definen de la siguiente manera:

$$\sigma_{f_k}^2 = \text{var}(B_{f_k}) \quad (3.1)$$

En el caso de ruido multiplicativo se obtiene el coeficiente de variación en el pixel de la siguiente manera (donde μ_{f_k} y σ_{f_k} representa la media y la desviación estándar respectivamente):

$$cv_{f_k} = \frac{\sigma_{f_k}}{\mu_{f_k}} \quad (3.2)$$

Figura 3.4: Toma de un bloque con $w = 1$ (3x3) pixeles.

Después de recorrer toda la imagen (como se muestra en la Figura 3.5) y aplicar las ecuaciones anteriores, se tiene dos matrices: varianzas locales y coeficientes de variación locales. De estas matrices podemos obtener:

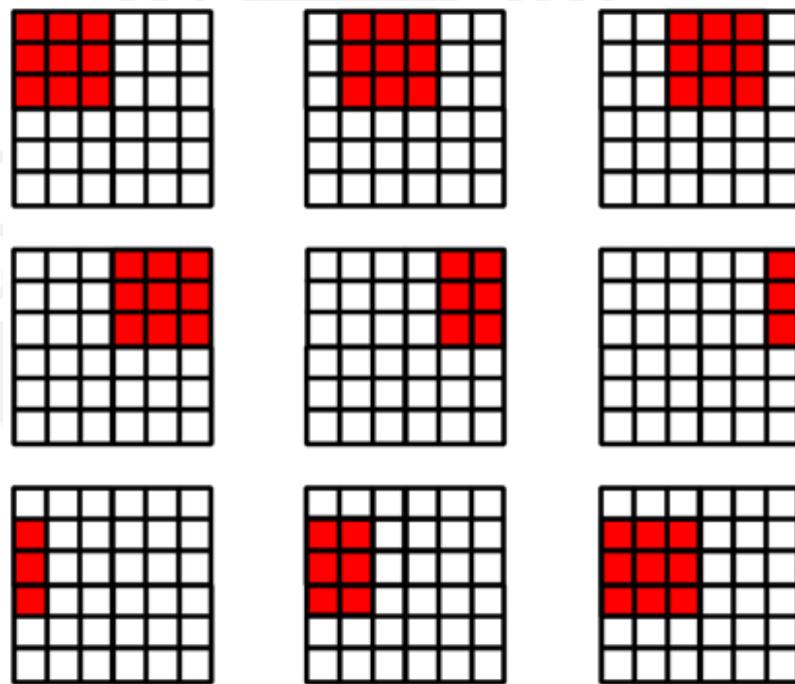


Figura 3.5: Movimiento del bloque por la imagen (3x3 pixeles).

Varianza estimada de f :

$$\sigma_f^2 = \frac{P - 3}{P - 1} \text{moda}(\sigma_{f_k}^2) \quad (3.3)$$

Coeficiente de variación estimado de f :

$$cv_f^2 = \text{moda}(cv_{f_k}^2) \quad (3.4)$$

Para el cálculo de la moda en ambos casos se utiliza un histograma (Figura 3.6).

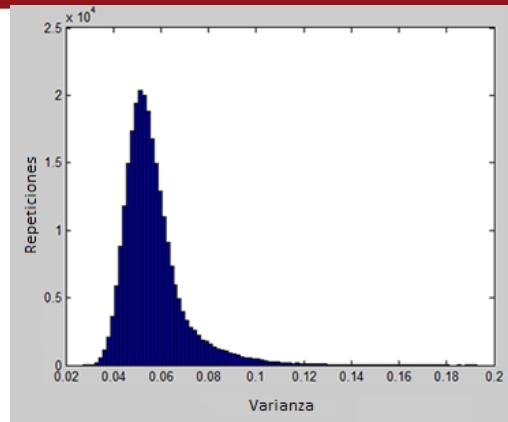


Figura 3.6: Histograma de varianzas sin filtrar.

Debido a ciertos casos en los cuales el histograma presenta irregularidades (especialmente en el caso de los coeficientes de variación), se utilizó una ventana de enmascaramiento Hanning. El cálculo de cada valor de la ventana está dado por:

$$b(k) = 0,5(1 - \cos(\frac{k\pi}{p})) \quad (3.5)$$

Donde $2p + 1$ representa el número de valores de la ventana. Luego de utilizar el filtro (aplicar convolución) se obtiene el histograma suavizado (Figura 3.7) de donde obtenemos la moda de las varianzas y de los coeficientes de variación.

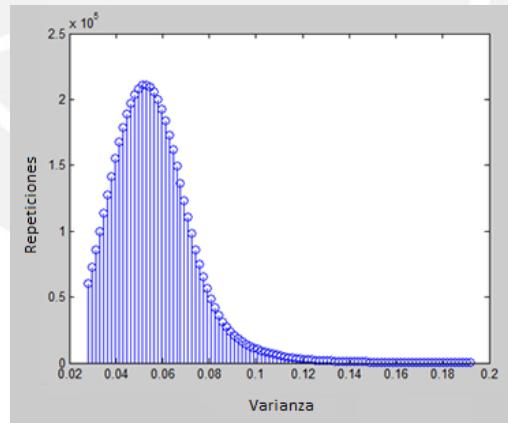


Figura 3.7: Histograma de varianzas filtrado.

A continuación, planteamos las ecuaciones para la varianza en el caso de ruido aditivo y el coeficiente de variación en el caso de ruido multiplicativo:

Ecuación de varianza:

$$\sigma_f^2 = \sigma_g^2 + \sigma_n^2 \quad (3.6)$$

Ecuación de coeficiente de variación:

$$cv_f^2 = (1 + cv_g^2) * cv_n^2 \quad (3.7)$$

Como la imagen analizada no presenta texturas considerables, es decir, la varianza de la imagen es despreciable, podemos decir que $\sigma_g^2 \approx 0$ y $cv_g^2 \approx 0$ por lo que:

Varianza estimada del ruido aditivo:

$$\sigma_f^2 = \sigma_n^2 \quad (3.8)$$

Coeficiente de variación estimado del ruido multiplicativo:

$$cv_f^2 = cv_n^2 \quad (3.9)$$

Para elegir el tamaño ideal de ventana para el estimador, se hicieron pruebas utilizando dimensiones de: 3x3, 5x5, 7x7, 9x9 y 11x11 pixeles. Se aplicó el estimador a imágenes corrompidas con ruido aditivo Gaussiano con valores de varianza de: 0.01, 0.05, 0.1, 0.5 y 1. La estimación de la varianza se realizó cien veces, de donde finalmente se obtuvo la media de los valores. Estos resultados se muestran en la Tabla 3.1:

Los resultados obtenidos afirman que las estimaciones para ventanas iguales o mayores a 5x5 pixeles ($w = 2$) presentan aproximadamente el mismo porcentaje de error, por lo que se tomó la decisión de utilizar ventanas predeterminadas de 7x7 pixeles ($w = 3$) debido al tiempo de procesamiento, el cual aumenta proporcionalmente al tamaño de w (Figura 3.8).

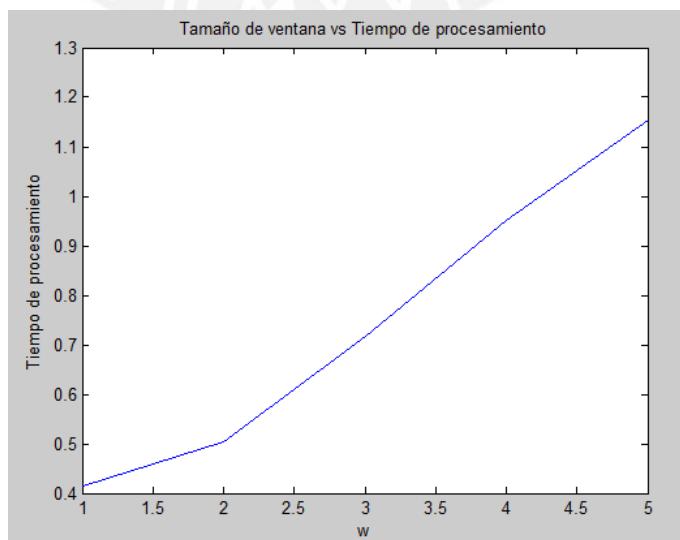


Figura 3.8: Tiempo de procesamiento en función al tamaño de ventana.

Tabla 3.1: Resultados de la estimación de la varianza de las imágenes utilizadas en el diseño contaminadas con ruido Gaussiano con varianzas $\sigma^2=0, 0.01, 0.05, 0.1, 0.5$ y 1 .

Imagen (Nombre)	Ventana (pixeles)	Varianzas obtenidas					
		0	0.01	0.05	0.1	0.5	1
BOATS	3x3	0.0006	0.0122	0.0574	0.1119	0.5529	1.1008
	5x5	0.0006	0.011	0.0528	0.1034	0.5058	1.0098
	7x7	0.0006	0.0112	0.0522	0.1026	0.5019	1.0008
	9x9	0.0019	0.0115	0.0524	0.1028	0.5024	0.9991
	11x11	0.002	0.0119	0.0525	0.1031	0.5024	0.9993
CAMERAMAN	3x3	0.0011	0.0127	0.059	0.1136	0.5527	1.0998
	5x5	0.0008	0.0119	0.0536	0.1046	0.5075	1.0106
	7x7	0.002	0.0121	0.0533	0.1038	0.503	1.0022
	9x9	0.0018	0.0123	0.0533	0.1039	0.5036	1.0005
	11x11	0.0027	0.0124	0.0534	0.1041	0.5042	1.001
GOLDHILL	3x3	0.0005	0.0129	0.0571	0.1116	0.5521	1.1
	5x5	0.001	0.0118	0.0528	0.103	0.505	1.0082
	7x7	0.0017	0.012	0.0527	0.1028	0.5017	0.9997
	9x9	0.0018	0.0122	0.0529	0.103	0.5013	0.9979
	11x11	0.0026	0.0126	0.0531	0.1034	0.5014	0.9985
LENA	3x3	0.0009	0.0117	0.0577	0.1128	0.5514	1.1015
	5x5	0.0007	0.0104	0.0524	0.1034	0.5069	1.008
	7x7	0.0007	0.0103	0.0515	0.1021	0.5025	1.0013
	9x9	0.0008	0.0102	0.0513	0.1019	0.5022	0.9995
	11x11	0.0008	0.0104	0.051	0.1018	0.5032	1.001
MANDRIL	3x3	0.0058	0.0182	0.0649	0.1201	0.5592	1.1047
	5x5	0.0067	0.0173	0.059	0.1102	0.5141	1.0156
	7x7	0.0063	0.0177	0.0587	0.1092	0.509	1.0072
	9x9	0.0061	0.0177	0.059	0.1095	0.5085	1.0053
	11x11	0.0061	0.0174	0.0592	0.1099	0.5089	1.0054
STRAW	3x3	0.0099	0.021	0.0666	0.1217	0.5615	1.1093
	5x5	0.0123	0.0222	0.0637	0.1144	0.5175	1.0194
	7x7	0.0135	0.0238	0.0642	0.1149	0.5137	1.012
	9x9	0.0145	0.025	0.0652	0.1156	0.5141	1.0115
	11x11	0.0164	0.0258	0.066	0.1162	0.5144	1.0117

3.3.2. VST utilizadas

Se utilizaron las diversas VST presentadas en el capítulo dos para los ruidos: Gamma, Rayleigh y Poisson. Como se aprecia, contamos con más de una VST para el caso de ruido Poisson, por lo que se realizaron pruebas para poder optar por la más adecuada. Las pruebas se hicieron sobre las imágenes del banco ya descrito contaminadas con ruido Poisson con valores de λ entre 0 y 250. Se aplicaron las tres VST (Anscombe, Bartlett y Freeman-Tukey) para luego estimar la varianza, esperando obtener varianzas unitarias. Los resultados se presentan en la Figura 3.9. De acuerdo a los resultados, la VST más eficiente es la transformada de Freeman-Tukey. Esta transformada se utilizó en el diseño del algoritmo discriminador de ruido.

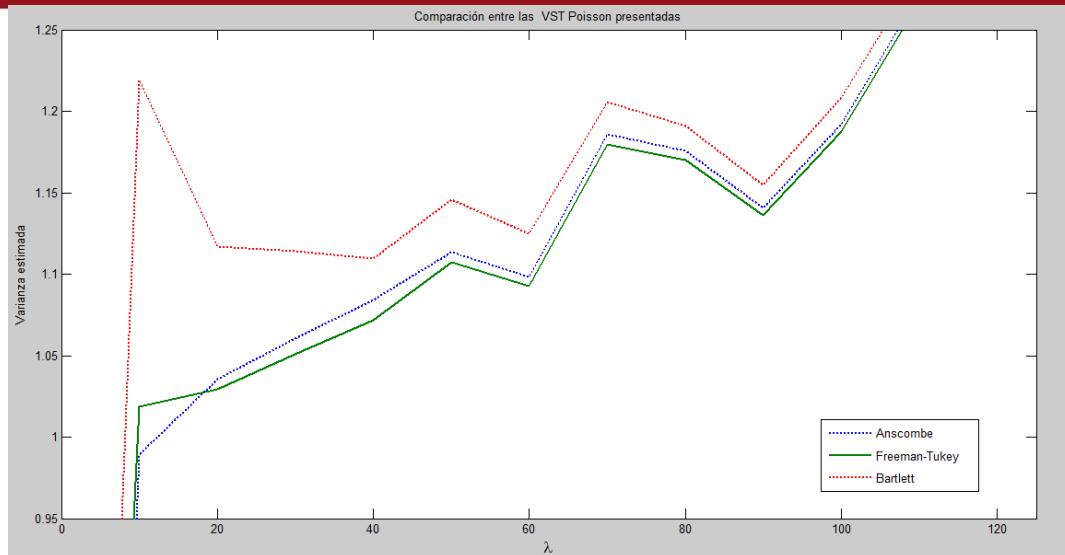


Figura 3.9: Comparación entre las tres VST Poisson propuestas.

3.3.2.1. Test estadístico de Lilliefors

Por otro lado, para poder discriminar el ruido Gaussiano, se utilizó el test estadístico de Lilliefors [34]. Este test es de normalidad, es decir, determina si un conjunto de datos sigue una distribución normal (Gaussiana) sin conocer la media ni la varianza del mismo. Está basado en el test de Kolmogorov-Smirnov, el cual se utiliza de la misma manera con la diferencia que este último no presenta resultados correctos si es que la varianza es desconocida. El resultado de estas pruebas es de tipo lógico (verdadero o falso), en un caso se aprueba la hipótesis (los datos siguen una distribución normal) y en otro, se rechaza.

3.3.3. Reglas de decisión

Para determinar las reglas se utilizó un programa de prueba. Este consistió en crear un arreglo de imágenes, a las cuales se les aplicó los cuatro tipos de ruido que se discuten en la tesis. Una vez que se obtuvo el arreglo completo, se aplicaron las tres transformadas (Gamma, Rayleigh y Poisson), el test de probabilidad de Lilliefors y el estimador de parámetros. Con los resultados se generaron cuatro gráficas, una por cada tipo de ruido. A continuación se muestran los resultados obtenidos para la imagen de Lena (Figuras: 3.10, 3.11, 3.12 y 3.13), la cual fue contaminada con 25 intensidades de cada uno de los cuatro ruidos, por lo que se obtuvieron 100 imágenes en total. Estas imágenes fueron procesadas cien veces para luego obtener un promedio.

El primer paso para determinar las reglas fue establecer los intervalos para los cuales la estimación de la varianza de cada transformada se aproximaba a la unidad. El propósito de estos intervalos fue poder obtener un resultado lógico (verdadero o falso) para cada transformada. Los intervalos se eligieron teniendo en cuenta los distintos cruces que existen en las gráficas, tratando de evitarlos para luego poder determinar reglas simples de discriminación. Los intervalos elegidos se muestran en la Tabla 3.2.

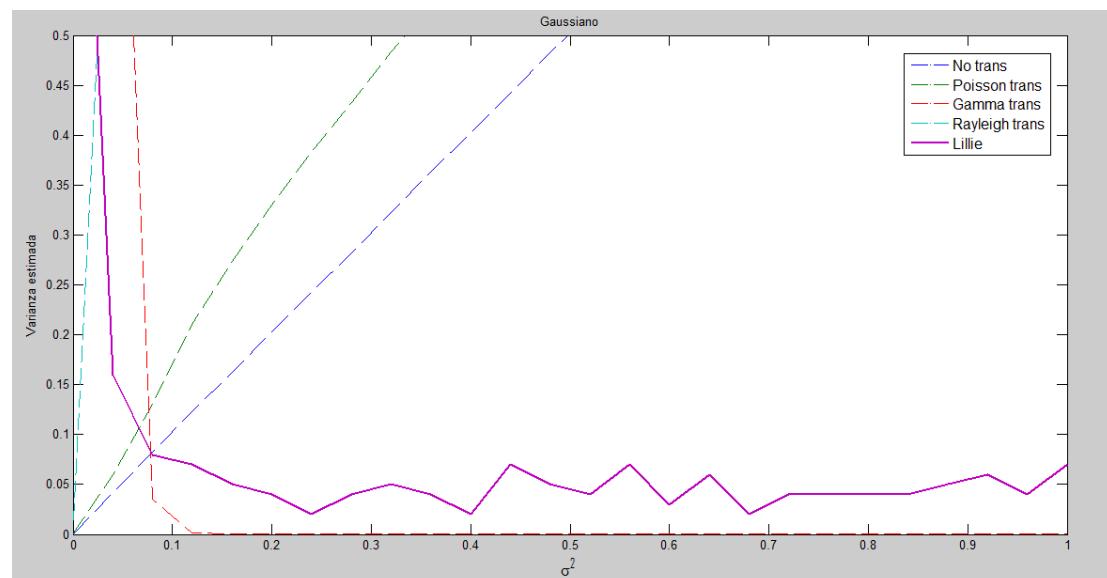


Figura 3.10: Gráfica de resultados para Lena con ruido Gaussiano.

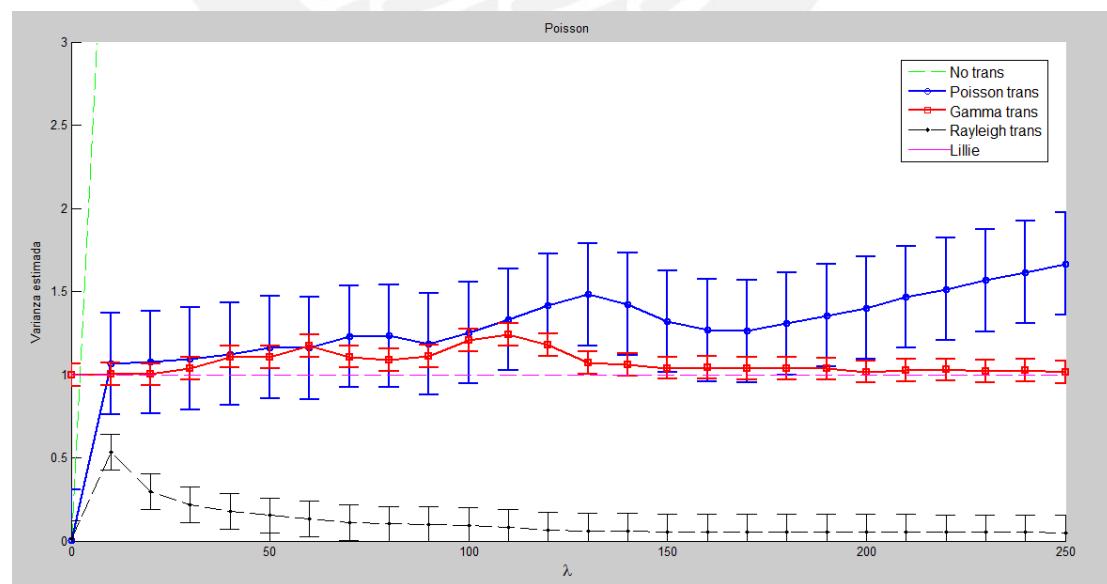


Figura 3.11: Gráfica de resultados para Lena con ruido Poisson.

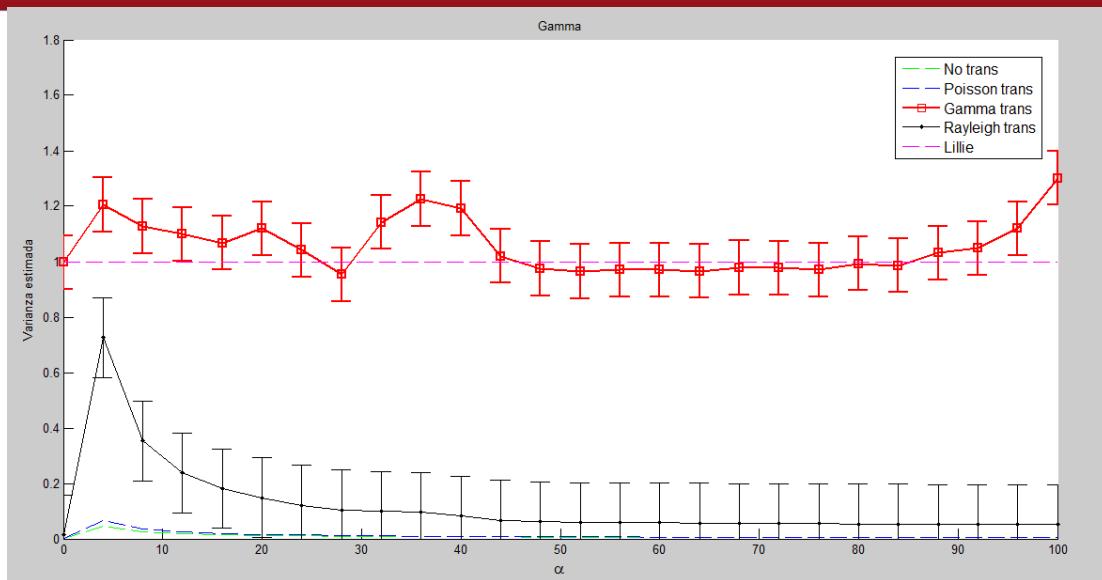


Figura 3.12: Gráfica de resultados para Lena con ruido Gamma.

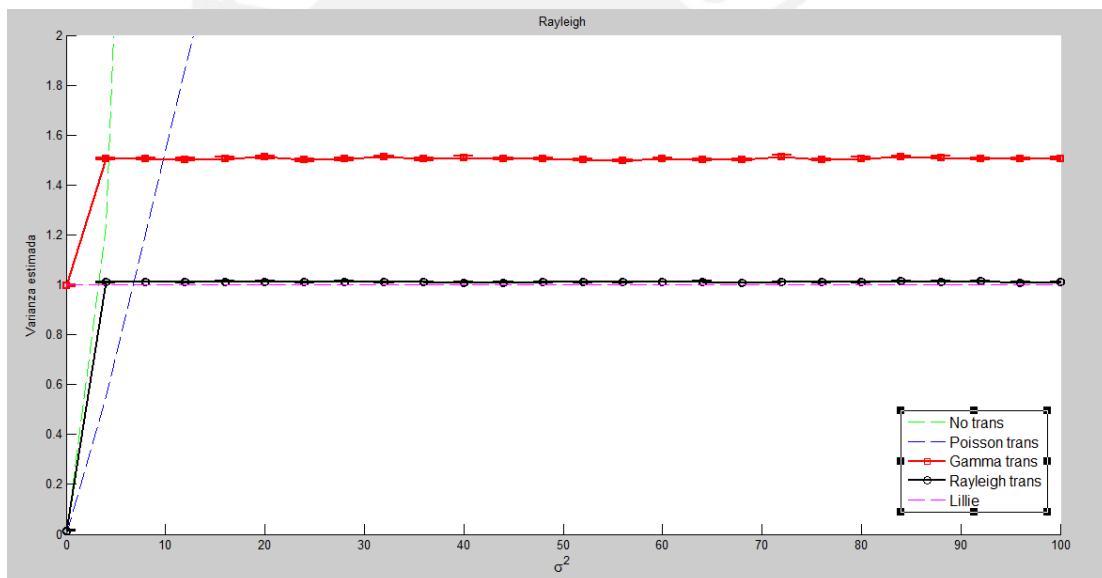


Figura 3.13: Gráfica de resultados para Lena con ruido Rayleigh.

Tabla 3.2: Intervalos.

Transformadas	Intervalos
Sin ruido	0 - 0.001
Poisson	0.5 - 2
Gamma	0.5 - 2
Rayleigh	0.8 - 1.2

Con los intervalos fijados se determinaron las reglas de discriminación finales, las cuales son la parte más importante y crucial de la tesis. Las reglas se muestran en la Tabla 3.3.

Tabla 3.3: Reglas.

Resultado	Transformadas		
	Poisson	Gamma	Rayleigh
Poisson	1	X	0
Gamma	0	1	0
Rayleigh	0	X	1

3.3.4. Discriminador de ruido

El discriminador de ruido es el algoritmo que recibe una imagen y devuelve un resultado que indica que tipo de ruido existe en la imagen y utiliza todas las herramientas que se han mostrado hasta este punto. Las herramientas que el algoritmo utiliza son las siguientes:

- Estimador de varianza y coeficiente de variación.
- VST para Gamma.
- VST para Rayleigh.
- VST para Poisson.
- Test de normalidad Lilliefors.
- Reglas de decisión.

En resumen, el algoritmo diseñado funciona de la siguiente forma:

1. Se recibe la imagen en cuestión y se estiman sus parámetros (varianza y coeficiente de variación).
2. Se analiza si la imagen no presenta ruido (varianza menor a 10^{-3}). Después se aplica el test estadístico de Lilliefors y las tres VST (Gamma, Rayleigh y Poisson).
3. Se estima la varianza de las imágenes transformadas (ruido aditivo Gaussiano) y se analizan los intervalos, obteniendo resultados de tipo lógico (verdadero o falso) y junto con el resultado de la prueba estadística, se aplican las reglas y se discrimina el ruido presente.

El algoritmo se muestra a continuación:

Algorithm 1: Discriminador de ruido.

Data: f : imagen analizada

Result: ruido: tipo de ruido presente

ESTIMADOR

$$[\sigma_f^2, cv_f^2] = \text{estimador}(f)$$

if ($\sigma_f^2 \leq 10^{-3}$) **then**

ruido = noiseless

else

$$H = \text{Lilliefors}(f_k)$$

$$F^{(\text{Poisson})} = \text{VSTpoisson}(f)$$

$$F^{(\text{Gamma})} = \text{VSTgamma}(f, cv_f^2)$$

$$F^{(\text{Rayleigh})} = \text{VSTrayleigh}(f)$$

$$\sigma_{F^{(\text{Poisson})}}^2 = \text{estimador}(F^{(\text{Poisson})})$$

$$\sigma_{F^{(\text{Gamma})}}^2 = \text{estimador}(F^{(\text{Gamma})})$$

$$\sigma_{F^{(\text{Rayleigh})}}^2 = \text{estimador}(F^{(\text{Rayleigh})})$$

REGLAS

if ($H ==$ verdadero) **then**

ruido = Gaussiano

else if ($0,5 \leq \sigma_{F^{(\text{Poisson})}}^2 \leq 2$) **then**

ruido = Poisson

else if ($0,8 \leq \sigma_{F^{(\text{Rayleigh})}}^2 \leq 1,2$) **then**

ruido = Rayleigh

else if ($0,5 \leq \sigma_{F^{(\text{Gamma})}}^2 \leq 2$) **then**

ruido = Gamma

else

ruido = Desconocido

Como se puede observar, el algoritmo presenta dos partes importantes. La primera parte se encarga de estimar los parámetros de la imagen y de sus transformaciones. La segunda parte se encarga de analizar los intervalos y aplicar las reglas para devolver un resultado (discriminación de ruido).

3.3.5. Obtención de variables características

Una vez discriminado el ruido podemos intentar obtener las variables que caracterizan al mismo (σ en el caso Gaussiano, α y λ en el caso Gamma, σ en el caso Rayleigh y por último λ en el caso Poisson). Para el caso de ruido aditivo utilizamos la ecuación de la varianza y para el caso de ruido multiplicativo utilizamos la ecuación del coeficiente de variación. Los casos se muestran a continuación.

Varianza caso aditivo Gaussiano:

$$\text{var} = \sigma^2 \quad (3.10)$$

Coeficiente de variación caso multiplicativo Gamma:

$$cv = \alpha^{-\frac{1}{2}} \quad (3.11)$$

Coeficiente de variación caso multiplicativo Rayleigh:

$$cv = \sqrt{\frac{4}{\pi} - 1} \quad (3.12)$$

Como vemos, según las ecuaciones mostradas solo podemos obtener el valor de σ del ruido aditivo Gaussiano y el valor de α del ruido multiplicativo Gamma, esto se debe a que el coeficiente de variación de la distribución Gamma no depende de λ así como no depende de σ en el caso de la distribución Rayleigh. En los dos casos mencionados, se requiere de un parámetro extra (media o varianza) para obtener dichas variables.

Capítulo 4

Implementación y resultados computacionales

El código de la función de discriminación de ruido se encuentra en el CD adjuntado al documento.

4.1. Consideraciones de implementación

4.1.1. Software de implementación

Se utilizó el entorno MATLAB® desarrollado por MathWorks en la versión 7.12.

4.1.2. Tamaño del bloque en el estimador de varianza

Se utilizaron bloques de tamaño predeterminado (7x7 pixeles) para la estimación de la varianza de la imagen. Esta decisión se tomó a partir de los resultados del diseño mostrados en el capítulo tres.

4.1.3. Características de las imágenes para la implementación

Las imágenes utilizadas en la implementación y resultados fueron distintas al banco de imágenes utilizado en el diseño, debido a que las reglas se obtuvieron a partir de ellas, y no tendría sentido alguno medir la efectividad del algoritmo con ellas. Las imágenes nuevas tienen un tamaño de 512x512 pixeles en escala de grises, cuyos pixeles fueron escalados en intensidad entre 0 y 1. Estas se presentan a continuación (Figura 4.1):

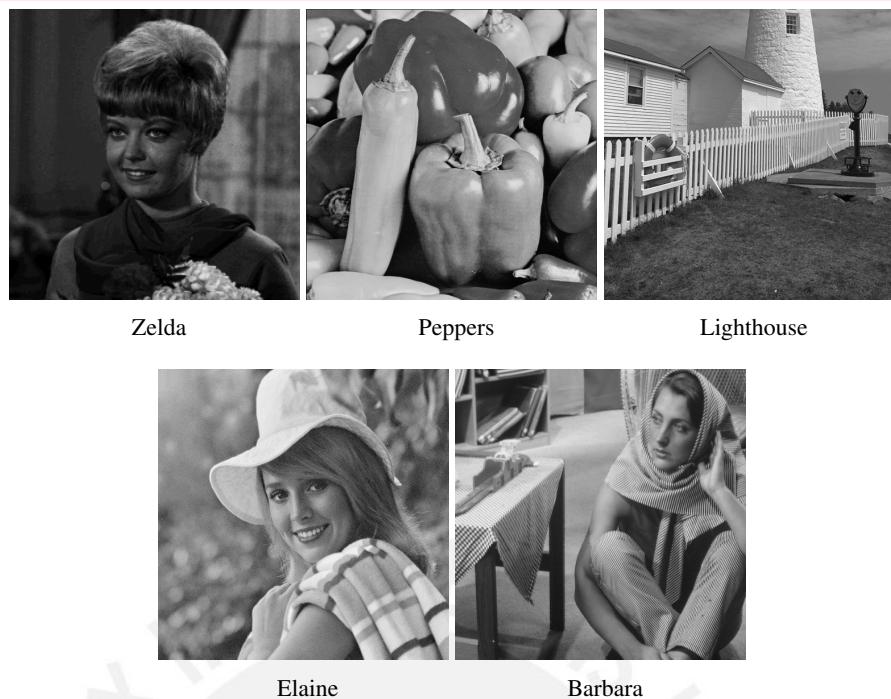


Figura 4.1: Banco de imágenes utilizado para la implementación y resultados del algoritmo.

4.2. Descripción de la implementación

La implementación del algoritmo consta de dos funciones: la función estimación de parámetros y la función discriminadora de ruido. En este caso, la función discriminación de ruido utiliza a la función estimación de parámetros como una sub-función.

4.2.1. Función estimación de parámetros

La función de estimación de parámetros recibe como entrada una imagen y devuelve a la salida dos parámetros: varianza del ruido (caso aditivo) y coeficiente de variación del ruido (caso multiplicativo). Se realizó la implementación inicial de esta función en la cual se utilizaron bloques de 7×7 pixeles que recorrían la imagen pixel por pixel. En este caso, se calculó la varianza local una a una, logrando resultados correctos pero en tiempos relativamente altos. Luego, se realizó una segunda versión en la cual se utilizó la misma cantidad de pixeles por bloque, pero en donde se aprovechó de mejor manera la capacidad vectorial del entorno (MATLAB), logrando los mismos resultados pero en menor tiempo. La comparación entre el tiempo de procesamiento entre ambas funciones se presenta a continuación (Figura 4.2):

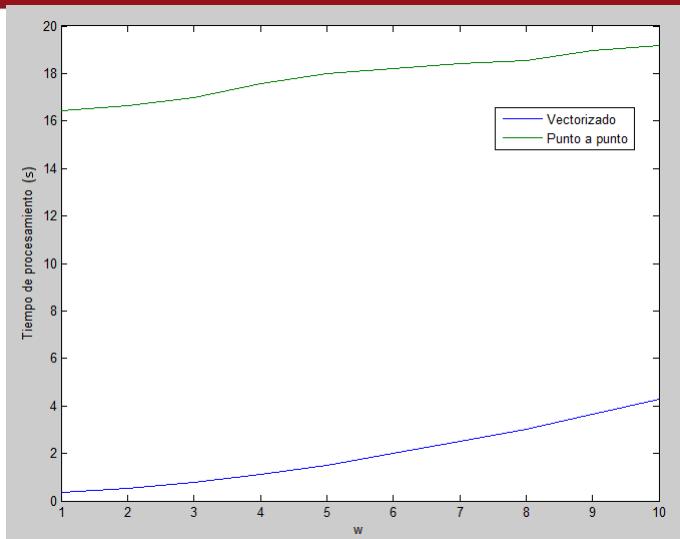


Figura 4.2: Comparación de estimación de varianza para diferentes tamaños de ventana.

4.2.2. Función discriminación de ruido

La función de discriminación de ruido recibe como entrada una imagen y devuelve a la salida la distribución de ruido presente en la misma. Se realizó la implementación de la función discriminación de ruido utilizando a la función de estimación de parámetros cuatro veces. La primera vez para obtener los parámetros iniciales de la imagen. Las siguientes tres para estimar los parámetros de las tres VST y poder aplicar las reglas de discriminación.

4.3. Resultados computacionales

4.3.1. Resultados del discriminador de ruido

Para determinar la capacidad de la función discriminación de ruido se utilizó un programa de prueba. En este programa se procesaron las imágenes del banco de implementación mostrado al inicio del capítulo. Estas fueron corrompidas con distintas intensidades de ruido Gaussiano, Gamma, Rayleigh y Poisson. El programa se ejecutó 100 veces para poder determinar un porcentaje de aciertos. Los resultados de la discriminación de ruido y de estimación de parámetros característicos se muestran en las Tablas 4.1, 4.4, 4.2 y 4.3.

4.3.2. Análisis de los resultados

Los resultados obtenidos y presentados en las tablas anteriores son alentadores. Se obtuvieron porcentajes de aciertos muy altos (de 100 % en su mayoría). Los principales errores en la discriminación (bajo porcentaje de aciertos) se dieron en 3 casos: sin ruido, Gaussiano y Poisson.

En el caso de imágenes sin ruido, el error de discriminación se debió a la textura que presentan las imágenes (Lighthouse y Barbara), por lo que la estimación de la varianza fue mayor a 10^{-3} , provocando que el discriminador presentara un porcentaje de aciertos de 0 % (en el caso sin ruido, las mismas imágenes se analizaron cien veces sin ningún cambio).

En el caso de ruido Gaussiano, los porcentajes de aciertos obtenidos fueron dados por el test estadístico de Lilliefors, por lo que no se puede determinar la razón del error o al menos no se encuentra dentro de lo abarcado por esta tesis. A pesar de esto, los porcentajes de aciertos se encuentran alrededor del 95 %, lo cual es aceptable.

Por último, los errores debido al ruido Poisson se deben a dos factores: los altos niveles de textura presente y los valores altos de λ (provocando una aproximación a distribuciones Gaussianas como fu explicado en el capítulo 2). Estos dos factores provocaron que la VST Poisson presentara una varianza mayor al intervalo planteado en las reglas y en ciertos casos identificándose, según el test de Lilliefors, como ruido Gaussiano.

Una vez discriminado el ruido, podemos obtener las variables que lo caracterizan basándonos en lo mencionado al final del capítulo 3.

Tabla 4.1: Resultados para ruido Gaussiano expresados en porcentaje de aciertos.

Imagen	Sin ruido	Gaussiano (σ^2)				
		0.2	0.4	0.6	0.8	1
ZELDA	100 % $\sigma^2=0.0006$	97 % $\sigma^2=0.2004$	93 % $\sigma^2=0.4003$	94 % $\sigma^2=0.593$	96 % $\sigma^2=0.7957$	95 % $\sigma^2=1.0037$
PEPPERS	100 % $\sigma^2=0.0007$	90 % $\sigma^2=0.2031$	96 % $\sigma^2=0.4051$	98 % $\sigma^2=0.6039$	91 % $\sigma^2=0.8001$	95 % $\sigma^2=1.0034$
ELAINE	100 % $\sigma^2=0.0005$	94 % $\sigma^2=0.2012$	94 % $\sigma^2=0.4056$	92 % $\sigma^2=0.5939$	95 % $\sigma^2=0.788$	95 % $\sigma^2=0.9978$
BARBARA	0 % $\sigma^2=0.2068$	92 % $\sigma^2=0.4042$	96 % $\sigma^2=0.6081$	92 % $\sigma^2=0.8025$	97 % $\sigma^2=1.0069$	94 %
LIGHTHOUSE	0 % $\sigma^2=0.2082$	88 % $\sigma^2=0.4101$	94 % $\sigma^2=0.6079$	95 % $\sigma^2=0.8094$	94 % $\sigma^2=1.0022$	91 %

Tabla 4.2: Resultados para ruido Gamma expresados en porcentaje de aciertos.

Imagen	Gamma (α)				
	10	20	30	40	50
ZELDA	100 % $\alpha=9.3152$	100 % $\alpha=19.2235$	100 % $\alpha=29.1516$	100 % $\alpha=39.8521$	100 % $\alpha=48.2656$
PEPPERS	100 % $\alpha=8.4778$	100 % $\alpha=18.6365$	100 % $\alpha=29.0632$	100 % $\alpha=38.8754$	100 % $\alpha=49.5236$
ELAINE	100 % $\alpha=8.8956$	100 % $\alpha=19.0591$	100 % $\alpha=27.9621$	100 % $\alpha=37.7845$	100 % $\alpha=51.9652$
BARBARA	100 % $\alpha=9.0258$	100 % $\alpha=17.1652$	100 % $\alpha=28.8695$	100 % $\alpha=38.9632$	100 % $\alpha=47.9481$
LIGHTHOUSE	100 % $\alpha=10.0287$	100 % $\alpha=16.9986$	100 % $\alpha=31.8745$	100 % $\alpha=42.4152$	100 % $\alpha=52.0125$

Tabla 4.3: Resultados para ruido Rayleigh expresados en porcentaje de aciertos.

Imagen	Rayleigh (σ)				
	0.2	0.4	0.6	0.8	1
ZELDA	95 %	100 %	100 %	100 %	100 %
PEPPERS	96 %	100 %	100 %	100 %	100 %
ELAINE	100 %	100 %	100 %	100 %	100 %
BARBARA	100 %	100 %	100 %	100 %	100 %
LIGHTHOUSE	100 %	100 %	100 %	100 %	100 %

Tabla 4.4: Resultados para ruido Poisson expresados en porcentaje de aciertos.

Imagen	Poisson (λ)				
	50	100	150	200	250
ZELDA	100 %	100 %	100 %	100 %	100 %
PEPPERS	100 %	100 %	100 %	100 %	100 %
ELAINE	100 %	100 %	100 %	100 %	100 %
BARBARA	100 %	100 %	99 %	0 %	0 %
LIGHTHOUSE	100 %	100 %	96 %	0 %	0 %

Conclusiones

- De acuerdo a los resultados finales se puede afirmar que es posible discriminar la distribución de ruido (Gaussiano, Poisson, Gamma y Rayleigh) presente en una imagen digital con poca textura de manera acertada. Esto permitirá asistir a diversas aplicaciones que requieran eliminar o reducir el efecto de algún ruido de manera eficiente con filtros particulares (ruidos específicos).
- Las reglas obtenidas al diseñar el algoritmo discriminador, de acuerdo a los resultados finales (sobre el banco de imágenes utilizado para la implementación y resultados), son escalables a una amplia gama de imágenes con la característica de poseer poca textura, al igual que las imágenes utilizadas para el diseño.
- En cuanto a la estimación de la varianza, los tamaños de ventana a partir de un radio $w = 3$ presentan resultados adecuados (error relativo $\leq 5\%$) para ser utilizados en la discriminación de ruido sin aumentar el número de discriminaciones erradas, por lo que se afirma que la ventana de radio $w = 3$ es la más eficiente, ya que minimiza el tiempo de procesamiento.
- Lamentablemente, el algoritmo desarrollado e implementado de manera secuencial, no presenta un tiempo de procesamiento suficientemente bajo para poder ser utilizado en ciertas aplicaciones de tiempo real en las cuales se cuenta con ventanas de tiempo muy reducidas (en el orden de los milisegundos). Un caso particular podría ser el área de visión por computadora, en donde se tiene por lo general una ventana de tiempo delimitada por la frecuencia a la cual un reproductor de video genera fotogramas (generalmente 60 cuadros por segundo).

Recomendaciones y observaciones

- Los algoritmos presentados, tanto para la estimación de varianza como para la discriminación de ruido, son altamente paralelizables debido principalmente a que constan de operaciones independientes en su mayoría. Esto se puede apreciar incluso en el diagrama de bloques presentado en el capítulo tres. Sería ideal desarrollar ambas funciones en algún lenguaje de programación en paralelo (p.e.: OpenMP, Pthreads, MPI [35], CUDA [36], SIMD [37], etc.) para poder disminuir el tiempo de procesamiento de manera considerable.
- Es recomendable buscar alguna forma de reducir los intervalos utilizados en las transformaciones de estabilización de varianza (especialmente para ruido Poisson) con algún método o transformación distinta, ya que ahí se encuentran las principales fuentes de error del discriminador.
- Sería importante realizar el análisis de los resultados del discriminador en imágenes de procedencia desconocida, comparando la eficiencia entre un filtro para la eliminación de ruido en general y un filtro para la eliminación de una distribución específica (obtenida como resultado de la discriminación inicial).

Bibliografía

- [1] A. Bovik, *The essential guide to image processing*. Academic Press, 2009.
- [2] A. Foi, “Optimization of variance-stabilizing transformations.” Artículo no publicado, Tampere University of Technology, Tampere, Finland., 2009.
- [3] S. Aja-Fernández, G. Vegas-Sánchez-Ferrero, M. Martín-Fernández, and C. Alberola-López, “Automatic noise estimation in images using local statistics,” *Image and Vision Computing*, vol. 1, pp. 756–770, 2009.
- [4] M. Pereyra, N. Dobigeon, H. Batatia, and J.-Y. Tourneret, “Segmentation of ultrasound image using a spatially coherent generalized rayleigh mixture model,” *19th European Signal Processing Conference*, pp. 664–668, 2011.
- [5] Y. Denga, Y. Wanga, and Y. Shenb, “Speckle reduction of ultrasound images based on rayleigh-trimmed anisotropic diffusion filter,” *Pattern Recognition Letters*, vol. 32, pp. 1516–1525, 2011.
- [6] K. Chehdi and M. Sabri, “A new approach to identify the nature of the noise affecting an image,” in *Acoustics, Speech, and Signal Processing, 1992. ICASSP-92., 1992 IEEE International Conference on*, vol. 3, pp. 285–288, mar 1992.
- [7] L. Beaurepaire, K. Chehdi, and B. Vozel, “Identification of the nature of noise and estimation of its statistical parameters by analysis of local histograms,” in *Acoustics, Speech, and Signal Processing, 1997. ICASSP-97., 1997 IEEE International Conference on*, vol. 4, pp. 2805–2808, apr 1997.
- [8] C. Wang, Z. Pan, Z. Zhang, W. Wei, and Q. Wang;, “A general variational model for multiplicative noise removal and its split bregman algorithm,” *Image and Signal Processing (CISP) 3rd International Congress on*, pp. 571–577, 2010.
- [9] S. Palakkal and K. Prabhu, “Poisson noise removal from images using the fast discrete curvelet transform,” *Communications (NCC) National Conference*, pp. 1–5, 2011.

- [10] H. Hwang and R. A. Haddad, "Adaptive median filters: new algorithms and results," *IEEE Transactions on Image Processing*, vol. 4, pp. 499–502, 1995.
- [11] P. Rodriguez and B. Wohlberg, "Efficient minimization method for a generalized total variation functional," *IEEE Transactions on Image Processing*, vol. 18, pp. 322–332, 2009.
- [12] F. Luisier, T. Blu, and M. Unser, "Image denoising in mixed poisson-gaussian noise," *Image Processing, IEEE Transactions on*, vol. 20, no. 3, pp. 696–708, 2010.
- [13] A. Rosenfeld, *Picture processing by computer*. New York: Academic Press, 1969.
- [14] Y. Chen and M. Das, "An automated technique for image noise identification using a simple pattern classification approach," in *Circuits and Systems, 2007. MWSCAS 2007. 50th Midwest Symposium on*, pp. 819–822, 2007.
- [15] J. Sijbers, "Automatic estimation of the noise variances from the histogram of a magnetic resonance image," *Physics in Medicine and Biology*, vol. 52, pp. 1335–1349, 2007.
- [16] M. Salmeri, A. Mencattini, E. Ricci, and A. Salsano, "Noise estimation in digital images using fuzzy processing," *Image Processing*, vol. 1, pp. 517–520, 2001.
- [17] J. Immerkaer, "Fast noise variance estimation," *Computer Vision and Image Understanding*, vol. 64, pp. 300–302, 1996.
- [18] S.-C. Tai and S.-M. Yang, "A fast method for image noise estimation using laplacian operator and adaptive edge detection," *Communications, Control and Signal Processing*, pp. 1077–1081, 2008.
- [19] B. Aiazzi, L. Alparone, and S. Baronti, "A robust method for parameter estimation of signal-dependent noise models in digital images," *Digital Signal Processing Proceedings*, vol. 2, pp. 601–604, 1997.
- [20] K. Rank, M. Lendl, and R. Unbehauen, "Estimation of image noise variance," *Vision, Image and Signal Processing*, vol. 146, pp. 80–84, 1999.
- [21] B. S. Everitt and A. Skrondal, *The Cambridge dictionary of statistics*. Cambridge University Press, 2010.
- [22] D. Montgomery, *Introduction to Linear Regression Analysis*. Wiley Series in Probability and Statistics, John Wiley & Sons, 2007.

- [23] P. Delientraz, *Transformaciones estabilizadoras de la varianza para datos de experimentos de microarreglos*. PhD thesis, Universidad de Buenos Aires, 2008.
- [24] F. J. Anscombe, “The transformation of poisson, binomial and negative-binomial data,” *Biometrika*, vol. 35, pp. 246–254, 1948.
- [25] O. Bustos, A. Flesia, and A. Frery, “Simulation of correlated intensity sar images,” *XII Brazilian Symposium on Computer Graphics and Image Processing*, p. 317, 1999.
- [26] S. M. Kay, *Intuitive probability and random processes using MATLAB*, ch. 5 & 6, pp. 105–166. Springer Science and Business Media, 2006.
- [27] L. D. Brown, T. T. Cai, and H. H. Zhou, “Nonparametric regression in exponential families,” *Annals of Statistics*, vol. 38, pp. 2005–2046, 2010.
- [28] J. Sijbers, A. den Dekker, J. V. Audekerke, M. Verhoye, and D. V. Dyck, “Estimation of noise in magnitude mr images,” *Magnetic Resonance Imaging*, vol. 16, pp. 87–90, 1998.
- [29] P. R. Prucnal and E. L. Goldstein, “Exact variance-stabilizing transformations for image-signal-dependant rayleigh and other weibull noise source,” *Applied Optics*, vol. 26, pp. 1038–1041, 1987.
- [30] M. Makitalo and A. Foi, “Optimal inversion of the anscombe transformation in low-count poisson image denoising,” *Image Processing, IEEE Transactions*, vol. 20, pp. 99–109, 2010.
- [31] S. Boslaugh and P. A. Watters, *Statistics in a nutshell*. O'Reilly Media, 2008.
- [32] M. S. Bartlett, “The square root transformation in the analysis of variance,” *Journal of the Royal Statistical Society*, vol. 3, pp. 68–78, 1936.
- [33] M. F. Freeman and J. W. Tukey, “Transformation related to the angular and the square root,” *Annals of Mathematical Statistics*, vol. 21, pp. 607–611, 1950.
- [34] H. W. Lilliefors, “On the kolmogorov-smirnov test for normality with mean and variance unknown,” *Journal of American Statistical Association*, vol. 62, pp. 339–402, 1967.
- [35] P. Pacheco, *An introduction to parallel programming*. Morgan Kaufmann, 2011.
- [36] J. Sanders and E. Kandrot, *CUDA by example: an introduction to general-purpose GPU programming*. Addison-Wesley Professional, 2010.

- [37] P. Cockshott and K. Renfrew, *SIMD programming manual for Linux and Windows*.
Springer Professional Computing, 2004.

